

GENERATIVE ADVERSARIAL NETWORK

Disusun oleh Kelompok 4

ANGGOTA KELOMPOK

- AGHNIYA AFIATUL J
- KAILLA SALSABILA
- SANDRA OKTAVIA K.P
- KARINA ISMAYA
- FAREN ANJANI M
- SUCI NURSANIA
- ALYA RAHMAWATI

GENERATIVE ADVERSARIAL NETWORK

Generative Adversarial Network (GAN) adalah jenis jaringan saraf tiruan yang digunakan untuk menghasilkan data sintetis yang mirip dengan data asli.

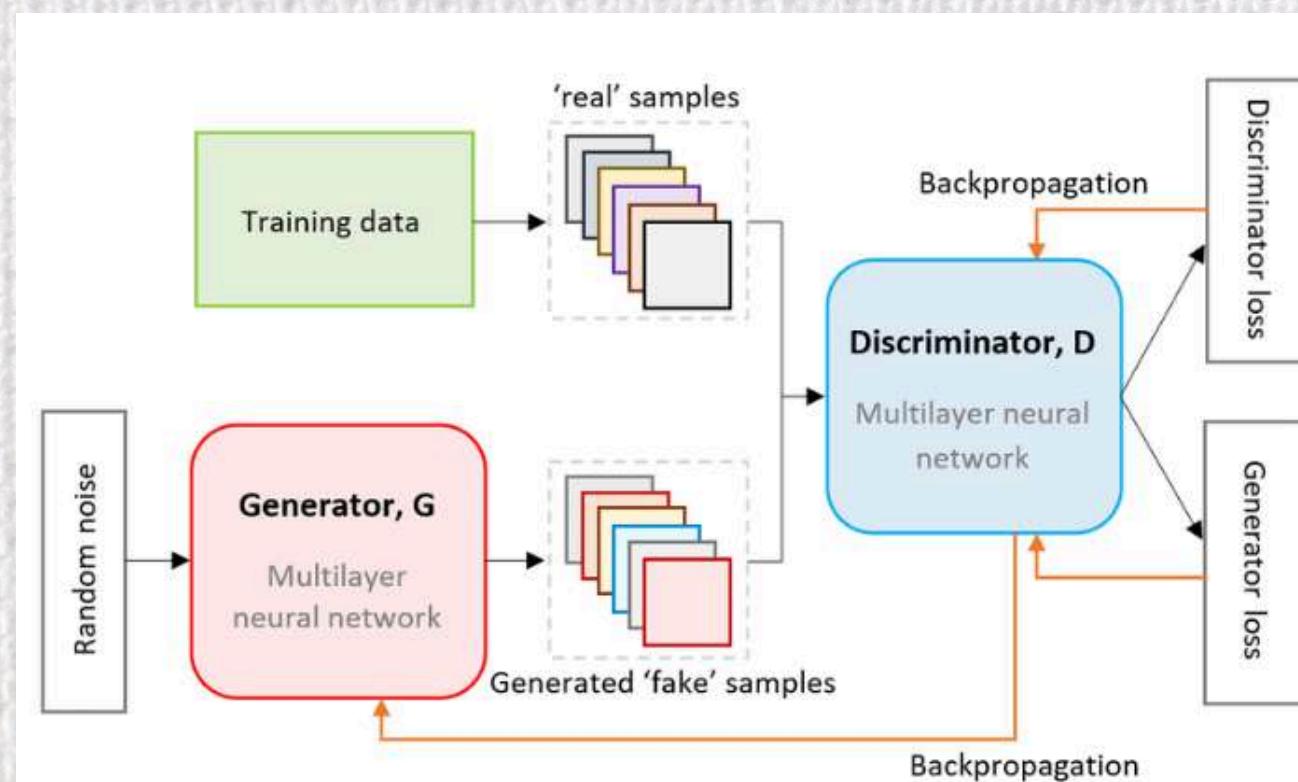
Komponen GAN:

- Generator: Jaringan saraf yang menghasilkan data sintesis.
- Discriminator: Jaringan Saraf yang mengevaluasi apakah data yang dihasilkan oleh generator adalah nyata atau palsu,

Cara Kerja GAN

- Generator menghasilkan data sintesis.
- Discriminator mengevaluasi data sintetis dan memberikan umpan balik kepada generator.
- Generator memperbaiki diri berdasarkan umpan balik dari discriminator.
- Proses ini berulang hingga generator dapat menghasilkan data sintetis yang sangat mirip dengan data asli.

PROSES PELATIHAN



1. Generator menghasilkan data sintetis: Generator menghasilkan data sintetis berdasarkan noise vektor (z).
2. Discriminator mengevaluasi data: Discriminator mengevaluasi data sintetis dan data asli untuk menentukan apakah data tersebut asli atau palsu.
3. Generator memperbaiki diri: Generator memperbaiki diri berdasarkan umpan balik dari discriminator.
4. Proses berulang: Proses pelatihan berulang hingga generator dapat menghasilkan data sintetis yang sangat mirip dengan data asli.

Dengan demikian, arsitektur GAN dapat digunakan untuk menghasilkan data sintetis yang realistik dan dapat digunakan dalam berbagai aplikasi.



KELEBIHAN GAN:

- Menghasilkan data sintetis yang realistik: GAN dapat menghasilkan data sintetis yang sangat mirip dengan data asli.
- Meningkatkan kualitas data: GAN dapat digunakan untuk meningkatkan kualitas data yang ada.
- Mengembangkan model yang lebih baik: GAN dapat digunakan untuk mengembangkan model yang lebih baik dalam berbagai bidang.

KEKURANGAN GAN:

- Kesulitan dalam melatih model: GAN dapat sulit dilatih dan memerlukan banyak data dan komputasi.
- Menghasilkan data yang tidak beragam: GAN dapat menghasilkan data yang tidak beragam jika tidak dilatih dengan baik.
- Ketergantungan pada data pelatihan: GAN sangat bergantung pada data pelatihan yang digunakan.



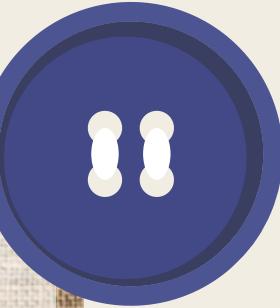
ARSİTEKTUR GAN

GENERATOR

- Input: Noise vektor (z) yang digunakan sebagai input untuk menghasilkan data sintetis.
- Arsitektur: Jaringan saraf tiruan yang terdiri dari beberapa lapisan, seperti:
 1. Lapisan input
 2. Lapisan tersembunyi (hidden layer)
 3. Lapisan output
- Fungsi aktivasi: Fungsi aktivasi yang digunakan untuk menghasilkan output yang diinginkan, seperti ReLU, Sigmoid, atau Tanh.

DISCRIMINATOR

- Input: Data asli atau data sintetis yang dihasilkan oleh generator.
- Arsitektur: Jaringan saraf tiruan yang terdiri dari beberapa lapisan, seperti:
 1. Lapisan input
 2. Lapisan tersembunyi (hidden layer)
 3. Lapisan output
- Fungsi aktivasi: Fungsi aktivasi yang digunakan untuk menghasilkan output yang diinginkan, seperti Sigmoid atau Softmax.



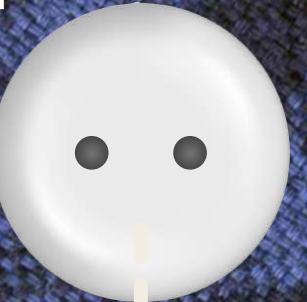


INPUT GAN [GENERATIVE ADVERSARIAL NETWORK]

- Noise Vektor: Input yang paling umum digunakan dalam GAN adalah noise vektor, yaitu vektor acak yang digunakan sebagai input untuk generator.
- Gambar: GAN dapat digunakan untuk menghasilkan gambar baru berdasarkan gambar yang ada. Input dapat berupa gambar itu sendiri atau fitur-fitur yang diekstrak dari gambar.
- Teks: GAN dapat digunakan untuk menghasilkan teks baru berdasarkan teks yang ada. Input dapat berupa teks itu sendiri atau fitur-fitur yang diekstrak dari teks.
- Audio: GAN dapat digunakan untuk menghasilkan audio baru berdasarkan audio yang ada. Input dapat berupa audio itu sendiri atau fitur-fitur yang diekstrak dari audio.
- Data Numerik: GAN dapat digunakan untuk menghasilkan data numerik baru berdasarkan data numerik yang ada. Input dapat berupa data numerik itu sendiri atau fitur-fitur yang diekstrak dari data numerik.
- Kondisi: GAN dapat digunakan untuk menghasilkan data yang sesuai dengan kondisi tertentu. Input dapat berupa kondisi itu sendiri atau fitur-fitur yang diekstrak dari kondisi.
- Data Multimodal: GAN dapat digunakan untuk menghasilkan data multimodal, yaitu data yang terdiri dari beberapa jenis data, seperti gambar dan teks.



APLIKASI GAN DALAM BERBAGAI BIDANG



X
X
X
X

X
X
X
X

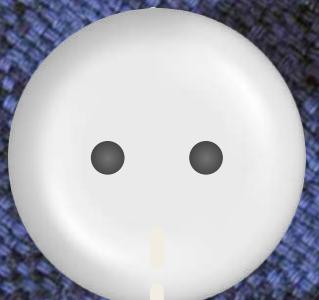
Pengolahan citra: GAN dapat digunakan untuk menghasilkan gambar yang realistik, mengedit gambar, dan lain-lain.

Pengolahan bahasa alami: GAN dapat digunakan untuk menghasilkan teks yang mirip dengan teks asli, meringkas teks, dan lain-lain.

Musik dan audio: GAN dapat digunakan untuk menghasilkan musik yang mirip dengan musik asli, mengedit audio, dan lain-lain.

Pengembangan model: GAN dapat digunakan untuk mengembangkan model yang lebih baik dalam berbagai bidang, seperti pengenalan wajah, pengenalan suara, dan lain-lain.

JENIS-JENIS GAN



Deep Convolutional GAN (DCGAN): Menggunakan arsitektur convolutional untuk menghasilkan gambar yang realistik.

Conditional GAN (CGAN): Menggunakan kondisi tertentu untuk menghasilkan data yang sesuai dengan kondisi tersebut.

StyleGAN: Menggunakan arsitektur yang dapat menghasilkan gambar dengan gaya yang berbeda-beda.

CycleGAN: Menggunakan arsitektur yang dapat menghasilkan gambar yang dapat diubah dari satu domain ke domain lain.

TANTANGAN DALAM MENGGUNAKAN GAN



1. Kesulitan dalam melatih model: GAN dapat sulit dilatih dan memerlukan banyak data dan komputasi.
2. Menghasilkan data yang tidak stabil: GAN dapat menghasilkan data yang tidak stabil jika tidak dilatih dengan baik.
3. Ketergantungan pada data pelatihan: GAN sangat bergantung pada data pelatihan yang digunakan.

MASA DEPAN GAN

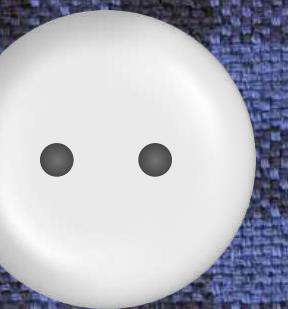
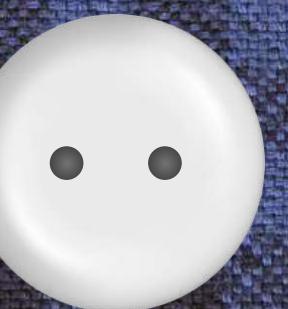


1. Pengembangan aplikasi yang lebih luas: GAN dapat digunakan dalam berbagai aplikasi yang lebih luas, seperti pengenalan wajah, pengenalan suara, dan lain-lain.
2. Peningkatan kualitas data: GAN dapat digunakan untuk meningkatkan kualitas data yang ada.
3. Pengembangan model yang lebih baik: GAN dapat digunakan untuk mengembangkan model yang lebih baik dalam berbagai bidang.

STUDI KASUS

KOMPUTER VISION DALAM BIDANG GENERATIVE AI

Dalam bidang Computer Vision, kebutuhan akan data gambar yang melimpah dan beragam sangat penting dalam pelatihan model pembelajaran mesin. Namun, mengumpulkan data gambar yang cukup sering kali menjadi tantangan, terutama pada domain spesifik seperti data medis, wajah, atau tulisan tangan. Selain itu, model pembelajaran mesin sering kali overfitting jika data latih terbatas. Maka, dibutuhkan metode yang mampu menghasilkan data baru yang menyerupai data asli. Di sinilah peran GAN menjadi penting sebagai pendekatan generatif yang mampu menciptakan data sintetis berkualitas tinggi.





KOMPUTER VISION DALAM BIDANG GENERATIVE AI

TANTANGAN

SOLUSI

Beberapa tantangan utama dalam pengembangan sistem GAN untuk kasus ini meliputi:

- Keseimbangan pelatihan: Generator dan Discriminator harus dilatih secara seimbang. Jika salah satu terlalu kuat, maka model tidak belajar dengan optimal.
- Kesulitan dalam konvergensi: GAN cenderung tidak stabil dan sulit untuk mencapai konvergensi (hasil stabil).
- Kualitas gambar: Pada tahap awal pelatihan, gambar yang dihasilkan Generator biasanya sangat buruk dan butuh waktu agar membaik.
- Overfitting: Discriminator bisa cepat belajar membedakan gambar asli vs palsu secara kasar tanpa memberi sinyal yang cukup kepada Generator untuk belajar.

Untuk mengatasi tantangan tersebut, solusi teknis dan pendekatan yang digunakan dalam studi kasus ini meliputi:

- Arsitektur sederhana: Menggunakan arsitektur GAN dasar (Multilayer Perceptron) sebagai langkah awal yang efisien.
- Dataset MNIST: Menggunakan dataset MNIST sebagai lingkungan pembelajaran awal karena ukurannya kecil, format gambar sederhana (28x28 piksel grayscale), dan data sudah bersih.
- Loss Function: Menggunakan Binary Cross Entropy Loss yang umum pada GAN untuk mengukur keberhasilan Generator dan Discriminator.
- Optimizer: Menggunakan Adam Optimizer untuk memastikan pembaruan bobot model yang stabil dan efisien.
- Regularisasi tidak eksplisit (early stopping manual): Proses pelatihan dipantau secara visual dan dihentikan saat Generator menghasilkan gambar yang cukup realistik.



KOMPUTER VISION DALAM BIDANG GENERATIVE AI

PROSES IMPLEMENTASI

a. Persiapan Data:

- Dataset MNIST diunduh dan dibagi dalam batch.
- Setiap gambar dinormalisasi ke nilai $[-1, 1]$ agar sesuai dengan output Tanh pada Generator.

b. Desain Model:

- Generator: Menerima input berupa vektor acak (noise) berdimensi 100 dan menghasilkan gambar ukuran 28x28 piksel.
- Discriminator: Menerima gambar (asli atau palsu) dan mengeluarkan nilai probabilitas (asli/palsu).

c. Pelatihan:

- Generator berusaha menipu Discriminator.
- Discriminator belajar membedakan gambar asli dan palsu.
- Kedua model dilatih secara bergantian hingga Generator menghasilkan gambar menyerupai angka tulisan tangan asli.

d. Visualisasi:

- Setiap beberapa epoch, hasil gambar dari Generator ditampilkan untuk memantau perkembangan model.



HASIL DAN ANALISIS

Hasil pelatihan menunjukkan bahwa:

- Pada awal epoch, Generator menghasilkan gambar acak yang tidak bermakna.
- Setelah sekitar 10-15 epoch, Generator mulai menghasilkan gambar yang menyerupai angka 0-9.
- Setelah 20 epoch, gambar yang dihasilkan semakin jelas dan dapat dikenali sebagai angka meskipun tidak sempurna.
- Model berhasil “menipu” Discriminator dengan tingkat akurasi yang semakin menurun seiring Generator menjadi lebih kuat.

Hasil ini menunjukkan bahwa GAN dapat digunakan untuk menghasilkan data sintetis berkualitas yang menyerupai data asli, bahkan dengan arsitektur sederhana. Studi kasus ini menjadi landasan untuk eksperimen lanjutan, seperti penerapan GAN pada dataset wajah manusia, citra medis, atau data domain-spesifik lainnya.

KESIMPULAN

Generative Adversarial Networks (GANs) adalah terobosan dalam machine learning yang memungkinkan dua jaringan saraf, generator dan diskriminator, bersaing untuk menghasilkan data sintetis yang sangat realistik, mulai dari wajah manusia hingga karya seni, dengan aplikasi luas dalam data augmentation, peningkatan gambar, dan kreasi konten. Meskipun kuat, GAN juga menghadapi tantangan signifikan seperti kesulitan pelatihan, potensi menghasilkan data tidak stabil (misalnya, deepfake), dan ketergantungan pada data pelatihan yang dapat memperkuat bias. Meskipun ada model generatif lain seperti VAE dan model difusi, GAN tetap relevan karena kualitas output visualnya yang superior dan sifat pembelajaran tanpa pengawasan, menjadikannya bidang penelitian yang dinamis dengan implikasi sosial dan etika yang terus dievaluasi.

**TERIMA
KASIH**

